

Licenciatura em Engenharia Informática

Deteção de Anomalias em Redes IoT com
algoritmos de Aprendizagem Máquina

LPEI

João Nogueira al81605

Luis Carvalho al81967

Vila Real, abril 2026

1. Introdução

Este projeto surge no âmbito da unidade curricular de Laboratório de Projeto em Engenharia Informática, na Universidade de Trás-os-Montes e Alto Douro (UTAD).

O objetivo principal consiste no desenvolvimento de uma plataforma de deteção de anomalias em redes IoT através da aplicação de algoritmos de Aprendizagem Máquina (*Machine Learning*). O trabalho foca-se no treino e otimização de diversos modelos, tanto supervisionados como não supervisionados, utilizando *datasets* de múltiplos protocolos de comunicação, nomeadamente MQTT, CICIDS2017 e Modbus.

A investigação permitirá avaliar o desempenho dos diferentes algoritmos e determinar quais os modelos mais adequados para a identificação de anomalias de rede e ataques externos. Por fim, os resultados e métricas obtidos serão apresentados numa interface *web* intuitiva, com recursos visuais e relatórios detalhados. Esta plataforma visa servir como ferramenta de apoio a estudantes, docentes e profissionais de cibersegurança e inteligência artificial no estudo e validação dos seus próprios modelos e dados.

2. Fontes de dados (Datasets)

A metodologia de análise estatística dos dados é um componente crítico do sistema, implementada através de um motor de análise dinâmico que compara o tráfego legítimo com comportamentos maliciosos. Este motor avalia a relevância de cada característica da rede utilizando métricas como o D de Cohen, que mede a magnitude da diferença entre grupos, e o teste de Mann-Whitney U para validar a significância estatística. Através desta análise, o sistema atribui um "score" de discriminação a cada característica, permitindo a seleção automática das mais eficazes para o treino da inteligência artificial e excluindo identificadores que possam viciar o modelo, como endereços IP ou portas de origem.

A arquitetura da plataforma organiza os algoritmos em diferentes categorias para otimizar a deteção de ameaças. São utilizados modelos supervisionados, como o *Random Forest*, que aprendem padrões específicos de ataques conhecidos, atingindo uma precisão base de aproximadamente 77,22% em dados MQTT. Paralelamente, aplicam-se métodos não supervisionados como o *Isolation Forest*, treinado apenas com tráfego normal para identificar anomalias sem necessidade de etiquetas prévias, e o *K-Means*, que agrupa o tráfego em *clusters* para isolar comportamentos minoritários suspeitos.

Os resultados e as métricas de desempenho de cada modelo são guardados num ficheiro JSON que inclui informações como a *Accuracy*, taxa de sucesso em relação ao total do dataset (tráfego normal e ataques), *Precision*, percentagem de acerto em relação aos dados reconhecidos como ataques/anomalias, *Recall*, número de ataques identificados corretamente em relação ao número real de ataques presentes nos dados analisados, *F1-Score*, média ponderada calculada entre o *Recall* e *Precision*.

3. Metodologia e Arquitetura do Sistema

A arquitetura da plataforma foi desenhada de forma modular para permitir o processamento sistemático de grandes volumes de dados provenientes de redes IoT, assegurando que cada etapa, desde a ingestão à classificação final, seja auditável e eficiente. O fluxo de trabalho inicia-se com o pré-processamento dos dados brutos, onde o sistema realiza uma limpeza profunda para eliminar inconsistências, tais como valores nulos ou infinitos, que frequentemente surgem em capturas de tráfego de rede. Nesta fase, é aplicada uma lógica de filtragem que remove identificadores específicos, como endereços IP e portas, garantindo que os modelos de aprendizagem máquina se foquem em padrões comportamentais e métricas estatísticas em vez de memorizar entidades específicas da rede.

Um componente central desta arquitetura é o motor de análise estatística, que atua como um filtro inteligente antes da fase de treino. Este módulo utiliza testes de hipóteses e medidas de dimensão de efeito para quantificar a capacidade de cada característica do tráfego em distinguir uma atividade normal de uma anomalia. Ao calcular métricas como o D de Cohen e o *p-value* de Mann-Whitney, o sistema consegue ordenar as variáveis pela sua relevância, permitindo que a plataforma selecione apenas os dados mais informativos. Esta abordagem não só melhora a precisão dos modelos, como também reduz a complexidade computacional, tornando o sistema mais ágil para futuras implementações em tempo real.

A inteligência da plataforma está estruturada numa pipeline que suporta múltiplas abordagens de modelação simultaneamente. No vertente supervisionado, utiliza-se o algoritmo Random Forest devido à sua robustez e capacidade de lidar com relações não-lineares nos dados de ataque. Complementarmente, a arquitetura integra modelos não supervisionados, como o Isolation Forest e o K-Means, que são fundamentais para detetar ataques desconhecidos ou variações comportamentais que não foram previamente etiquetadas. Todo este ecossistema é suportado por uma estrutura de armazenamento em formato JSON, onde são registados os "boletins de desempenho" de cada modelo, facilitando a posterior exportação de métricas e visualizações para a interface web de monitorização.

4. Implementação e Treino dos Modelos de Aprendizagem Máquina

A fase de modelação do projeto assenta numa abordagem híbrida, combinando técnicas de aprendizagem supervisionada e não supervisionada para cobrir o espectro completo de ameaças em redes *IoT*. No núcleo da componente supervisionada encontra-se o algoritmo *Random Forest*, selecionado pela sua capacidade intrínseca de lidar com grandes volumes de dados e pela sua resistência ao sobre ajuste através da criação de múltiplas árvores de decisão. Este modelo é alimentado com um conjunto de dados previamente etiquetado, permitindo-lhe aprender as assinaturas específicas de ataques conhecidos, como *brute-force* ou *scans* de portas. Durante o treino, o sistema utiliza técnicas de validação cruzada para garantir que a inteligência artificial não está apenas a memorizar os dados, mas sim a generalizar comportamentos que permitam identificar variações de ataques futuros.

Simultaneamente, a plataforma implementa uma camada de deteção de anomalias puras através de algoritmos não supervisionados, sendo o Isolation Forest o principal protagonista. Ao contrário dos modelos tradicionais que tentam definir o que é um ataque, o Isolation Forest foca-se em isolar observações que se desviam drasticamente do padrão de tráfego normal. Esta técnica é particularmente valiosa no contexto de cibersegurança *IoT*, pois permite a identificação de ataques de dia zero (*zero-day*) ou comportamentos anómalos que ainda não foram catalogados em bases de dados de assinaturas. A arquitetura é ainda reforçada com a aplicação do algoritmo K-Means, que agrupa os fluxos de rede em *clusters* baseados em semelhanças estatísticas, facilitando a separação entre comunicações legítimas de sensores e atividades intrusivas que tendem a formar grupos isolados e minoritários.

Para garantir a transparência e a reprodutibilidade das experiências, todo o processo de treino é acompanhado pela geração automática de métricas de desempenho. Após cada iteração, o sistema calcula e exporta indicadores fundamentais como a precisão (*accuracy*), a revocação (*recall*) e a pontuação F1, que são armazenados em ficheiros de metadados. Estes relatórios não só validam a eficácia de cada algoritmo, como também permitem realizar uma análise comparativa entre os diferentes protocolos de comunicação, determinando qual o modelo que melhor se adapta às características específicas do tráfego MQTT ou Modbus. Este ciclo de treino e avaliação contínua assegura que a plataforma evolua conforme a complexidade das ameaças de rede aumenta.

5. Interface Web

A interface web da plataforma foi desenhada para ser intuitiva e acessível, funcionando como um painel de controlo interativo que traduz os resultados técnicos gerados pelos algoritmos em visualizações compreensíveis. Abaixo descrevem-se as principais funcionalidades à disposição do utilizador:

5.1 Navegação e seleção de dados

Ao aceder à aplicação, o utilizador pode explorar os resultados dos treinos previamente guardados em ficheiros JSON.

O utilizador tem a capacidade de alternar entre os resultados obtidos nos diferentes conjuntos de dados analisados, como os fluxos do protocolo MQTT (biflow) ou o conjunto de dados mais complexo CICIDS2017.

Para implementação futura vamos implementar uma funcionalidade para o utilizador importar ficheiros com os seus próprios dados, seguindo regras de padronização de nomes, para poder treinar e comparar modelos baseados nos seus próprios dados.



Figura 1 – Menu de seleção de fonte de dados

5.2. Painel de Desempenho e Métricas

Esta secção permite a validação rápida da eficácia de cada modelo de *Machine Learning*.

A interface apresenta os indicadores de desempenho fundamentais calculados durante a fase de testes: **Accuracy** (Precisão global), **Precision** (Taxa de anomalias corretamente detetadas), **Recall** (Taxa de deteção ou revocação) e **F1-Score**.

A interface apresenta também um menu para seleção do modelo pretendido.




Figura 2 – Dashboard de visualização de métricas do treino de cada modelo

Na aba de “Comparação de modelos”, o utilizador é apresentado a gráficos de barras que servem como ferramenta de comparação dos resultados dos diferentes modelos.




Figura 3.1 – Dashboard de comparação de modelos

O utilizador também tem a opção de seleccionar quais modelos pretende comparar clicando nas legendas, à direita do gráfico.




Figura 3.2 – Gráfico de comparação apenas com o Random Forest




Figura 3.3 – Dashboard de Comparação apenas com o Isolation Forest e K-Means Seleccionados

No futuro planeamos adicionar uma feature para exportação destes dados, em formato JSON ou .csv, para permitir ao utilizador criar os seus próprios gráficos e reports.

6. Resultados Obtidos e Conclusões

6.1 Desempenho: Random Forest vs. Modelos Não Supervisionados

Durante a fase de testes, o algoritmo *Random Forest* destacou-se com um desempenho manifestamente superior em comparação com abordagens não supervisionadas, como o *Isolation Forest* e o *K-Means*. Esta discrepância justifica-se pela natureza da aprendizagem: o *Random Forest*, sendo supervisionado, utiliza as etiquetas (labels) pré-definidas de tráfego normal e de ataque para criar regras de decisão exatas. Por outro lado, o *Isolation Forest* foca-se puramente na deteção de anomalias estatísticas. No contexto de redes IoT (como no protocolo MQTT), um ataque inteligente ou de força bruta pode apresentar uma assinatura matemática muito semelhante ao tráfego normal, elevando a taxa de falsos positivos nestes modelos puramente focados em desvios comportamentais.

6.2. A Inadequação do Algoritmo K-Means

O modelo *K-Means* apresentou os resultados mais fracos do estudo. Isto deve-se ao facto de o algoritmo agrupar dados medindo a distância geométrica entre eles, assumindo que diferentes classes formam agrupamentos esféricos distintos. A realidade do tráfego de rede é altamente não-linear e sobreposta; um pacote de um ataque de *Bruteforce* via MQTT pode ter o mesmo tamanho e tempo de chegada que um pacote benigno. Ao forçar a separação geométrica, o *K-Means* acaba por misturar amostras de ataques com tráfego legítimo, degradando drasticamente métricas como a *Accuracy* e a *Precision*.

6.3. O Impacto da Qualidade das *Features* (CICIDS2017 vs. MQTT/Biflow)

Uma das conclusões mais relevantes deste projeto prende-se com a disparidade de resultados entre diferentes conjuntos de dados. Os modelos treinados com o dataset *CICIDS2017* obtiveram resultados consideravelmente melhores do que os treinados com os fluxos do protocolo MQTT (*biflow*). Esta diferença não advém de falhas nos algoritmos, mas sim da riqueza de informação (*features*) extraída. Enquanto o dataset MQTT se baseia largamente em métricas de contagem (número e tamanho de pacotes) e intervalos de tempo básicos, o *CICIDS2017* fornece dezenas de métricas comportamentais avançadas, tais como a velocidade do fluxo (*Flow Bytes/s*), tempos de atividade/inatividade (*Active/Idle Mean*) e tamanhos de janelas TCP. Esta riqueza de *features* comportamentais permite aos modelos, particularmente ao *Random Forest*, detetar rapidamente picos anómalos associados a ataques de *scan* ou *bruteforce*, algo substancialmente mais complexo de inferir com os dados limitados do ambiente MQTT.

Em suma, o projeto atingiu os objetivos iniciais de criar uma infraestrutura capaz de processar, analisar e classificar eventos de rede com um elevado grau de automatização. A integração de métricas estatísticas rigorosas com algoritmos de IA resultou numa ferramenta que não só deteta intrusões, mas também oferece transparência sobre as razões que levaram a essa classificação. A transposição destes resultados para uma interface web interativa permitiu democratizar o acesso a estas conclusões. A dashboard implementada consome dinamicamente os ficheiros JSON resultantes dos treinos, transformando dados técnicos e métricas de desempenho em relatórios visuais acionáveis, consolidando a utilidade prática desta plataforma no panorama da cibersegurança.